HyperDesign —— 本地部署的自进化制造业产品设计 AI 系统

作品介绍文档 · 从「像素逼真」到「几何真实」的制造业生成式 AI 全链路

项目编号：proj_20261014_001 ｜ 示范产品：工业级无线振动 / 温湿度三合一传感器外壳（120 × 80 × 45 mm，PC+ABS 上盖 + 铝合金 CNC 底座）

代码仓库：**https://github.com/runming/HyperDesign** ｜ 演示视频：`docs/demo/HyperDesign_Demo_1080p.mp4`（1 分 46 秒，1080p）

文档版本：v1.0 ｜ 日期：2026-10-16

100% 本地部署 | 私有工艺 RAG | Text-to-CAD 自愈闭环 | DFM 物理硬约束 | DPO 自进化飞轮 | 国标制图直连 | 单卡消费级硬件

一、项目背景与行业痛点

在工业制造与硬件产品研发领域，生成式 AI（AIGC）的落地长期面临一道巨大的「车间鸿沟」——现有的图文生成与 3D 娱乐大模型虽能产出极具视觉冲击力的渲染图，却无法真正服务于生产制造。其核心症结在于四大行业痛点：

痛点 1：「像素幻觉」与「工程现实」脱节

传统 2D 生图工具（Midjourney / Stable Diffusion）生成的工业产品充斥违反物理规律的透视与光影伪影；主流 3D 生成模型导出的仅是拓扑杂乱、无物理毫米尺寸、非水密的三角网格（Mesh），无法直接用于 CNC 加工、注塑开模或钣金折弯。

痛点 2：缺乏可制造性设计（DFM）底层约束

通用大模型不具备企业私有的产线经验（特定机台的最小壁厚、拔模斜度、折弯扣除系数），生成方案常在结构评审阶段因无法脱模、壁厚不均或装配干涉而全盘推翻。

痛点 3：跨模态试错成本高昂

直接在参数化 CAD 阶段探索造型，修改周期极长；而在 2D 阶段探索，又缺乏自动化机制将「感性的视觉比例」无损还原为「理性的 B-Rep（边界表示法）参数化实体」。

痛点 4：数据隐私红线与模型进化难题

制造业核心工艺标准与历史图纸属高度机密，严禁上传公有云 API；同时企业需要一套零边际成本机制，把资深工程师日常的「审图判断」持续沉淀给本地模型，而非依赖昂贵算力集群重新预训练。

> **核心工程理念：设计可信度来自几何真实存在，而非像素逼真。** HyperDesign 打造了一套 100% 本地化部署、打通「概念发散 → 白模收敛 → 参数化 CAD → 生产工程图 → DPO 偏好自进化」全闭环的制造业 AI 系统。

二、系统技术架构

HyperDesign 采用「**多环境隔离解耦 + 统一事务状态机（`manifest.json`）+ 显存红绿灯动态调度**」的工程架构，将产品研发周期划分为 7 个紧密咬合的阶段。所有阶段的输入输出都汇聚到同一份 `manifest.json` 数据契约中，任一阶段可独立重跑而不破坏上下游。



2.1 四层核心技术栈

层级	阶段	技术组成与职责
认知与知识检索层	Phase 1	Qdrant 向量库 + `BAAI/bge-m3` 稠密向量（1024 维 COSINE）+ Ollama 本地大模型；实现企业注塑 / CNC / 钣金规范的精准检索与**硬性参数注入**，并以「规范数值必须原样引用」为铁律约束生成。
视觉与三维网格层	Phase 2–4	ComfyUI API 驱动 FLUX.2-dev 批量生成符合三维重建几何锚点的 2D 概念图；WSL2 容器化封装的 `TRELLIS-image-large` 恢复三维结构；Windows 原生 Blender 无头脚本完成减面、水密化与真实毫米尺寸校准；前端基于原生 ES Module 的 Three.js 零构建审阅台。
计算几何与制图交付层	Phase 5–6	Trimesh 提取白模多高度截面比例，驱动 FreeCAD / CadQuery（OpenCascade 内核）生成全参数化 B-Rep 实体（`.step`）；OCC HLR（隐藏线消除）算法 + ezdxf 自动绘制符合 GB/T 图层标准的 2D 工程图（`.dxf` / `.pdf`），并预留 COM 接口对接浩辰 / 中望 / AutoCAD。
评判与自进化层	Phase 7	法向射线测厚（Ray-Casting）+ 拔模斜度场分析 + 本地 VLM 视觉评分 + Unsloth 4-bit QLoRA / DPO 训练框架；配黄金基准测试集（Benchmark）回归验证的本地模型迭代流水线。

2.2 本机落地技术栈（可复现的真实配置）

下表为本项目实际跑通所用的组件与版本；括号内标注与《工程文件》规划稿有差异的部分，全部差异与原因记录于仓库 `issues.md`（24 条）。

组件	本机实际配置	说明 / 规划稿差异
推理显卡	NVIDIA RTX 5080 16GB（单卡）	全链路最紧资源，需显存接力调度
主控大模型	`qwen38-uncensored-128k`（27.3B，Ollama 本地）	规划稿为 Qwen3.5-9B，本机不可得
视觉初筛 VLM	`qwen3.7-flash`（8.3B）	规划稿为 Qwen2.5-VL-7B
向量库	`qdrant-client` 嵌入式持久化	宿主无 Docker，改用嵌入式（接口语义一致）
向量模型	`BAAI/bge-m3`（fp16，1024 维）	与规划一致
出图引擎	ComfyUI 0.9.1 + `flux2_dev_fp8mixed` + Mistral-3-Small 文本编码器	规划稿为 FLUX.1-dev；本机权重为 FLUX.2-dev
3D 重建	WSL2 + TRELLIS-image-large（torch 2.11.0+cu128 / spconv / xformers）	与规划一致（`ATTN_BACKEND=xformers`、`SPCONV_ALGO=native`）
网格精修	Blender 4.2.9 便携版无头脚本	与规划一致（`blender-mcp` 未启用，流程全自动）
CAD 内核	**FreeCAD 1.1.4 自带 OpenCascade**（104 `freecadcmd` 无头校验）	本机 OCP/CadQuery 原生扩展无法加载（见 issues #6），改用工程文件同样指定的 FreeCAD；CadQuery 版实现保留备查
制图与打印	ezdxf 1.4 + matplotlib 3.11（A3 300dpi）	与规划一致
进化训练	WSL2 Unsloth 2026.10.6 + torch 2.11.0+cu128 + Qwen2.5-7B-Instruct-bnb-4bit	与规划一致（QLoRA r16 / DPO beta 0.1）

2.3 关键实测指标（本机一次完整跑通的真实数据）

阶段节点	实测结果	工程含义
私有规范引用校验	**PASS**	回答逐字引用 **2.4 mm** / **1.44 mm** / **≥1.8°**，拒绝通用 2.0 mm
概念图生成	4/4 张，114–136 s/张	1024²、base_seed=88400、纯灰背景、无裁切
VLM 初筛	几何清晰 8 / 制造可行 9 / 需求对齐 8	四张方案一致性良好
TRELLIS 重建	17–32 s/次	WSL2 微服务 `:8003`，sparse12/cfg7.5 + slat12/cfg3.0
Blender 清洗	973,462 → **388,391** 面；X=120 mm；Z_{min}=0	毫米级物理对齐，底面坐平工业基准面
参数化 CAD 自愈	**第 1 轮一次通过**	BRep `isValid()=True`，体积 **69,042.2 mm³**，包络 **120.0 × 80.0 × 45.0 mm（偏差 0）**
工程图输出	510 条轮廓 + 3 处检验尺寸 + 标题栏	图层 `CUT_PROFILE / HIDDEN_LINE / DIMENSIONS / TITLE_BLOCK` 分离
DFM 硬校验（白模）	**未通过**	水密=否 / p10 壁厚 1.51 mm / 立面拔模 0.84°——生成式网格固有特性，白模仅作造型比例锚点（见第五节）
进化与守门员	LoRA 训练成功（0.52% 参数，27.6 s）→ GGUF Q4_K_M → 注册 `hd-brain:v20261016_1326`	黄金基准回归：旧模型 Pass@1 = 1/1，进化版 0/1 → **allowed_to_switch = false，禁止切流**

三、核心应用场景

场景 1｜工业外壳与结构件敏捷开发（注塑 / 压铸）

场景描述：针对智能硬件外壳、工业传感器护罩、手持终端等产品，工程师仅需输入一句功能描述与安装尺寸包络，系统自动调取车间注塑机规范（如强制名义壁厚 **2.4 mm**、拔模角 **≥1.8°**），在一次会话内完成从 4 组差异化造型探索到可报价 `.step` 实体模型的转化。

本机实证：4 张概念图 ≈ 9 min（114–136 s/张）→ TRELLIS 重建 32 s → Blender 清洗 9 s → CAD 代码生成 466 s → OCC 校验通过，产出 `parametric_model.step`（54.9 KB，BRep 合法）+ 参数化源码。

场景 2｜钣金与激光切割件快速排产（激光 / 数控折弯）

场景描述：针对设备支架、控制盒底座、法兰转接板等零件，系统生成参数化三维模型后，Phase 6 自动剥离图框与尺寸线，直出 1:1 纯净外轮廓与孔位 `laser_1to1.dxf`，可直接导入柏楚 CypCut 等激光切割 CAM 软件排料切割。

本机实证： `proj_20261014_001_laser_1to1.dxf`（TOP 投影 82 条轮廓实体，仅 `CUT_PROFILE` 图层、零尺寸线污染）。

场景 3｜非标机械零部件系列化派生

场景描述：Phase 5 产出的并非死模型，而是带顶部全局参数表的标准参数化源码（`LENGTH_X`、`BOSS_INSET`、`WALL_THICKNESS` 等），结构工程师只需修改变量，即可在 1 秒内派生出同产品家族不同规格的 `.step` 与 `.dxf` 图纸。

本机实证： `05_cad/parametric_model.py` 顶部参数表 + 注释齐全；自愈引擎即以此文件为「可复现资产」而非一次性脚本。

场景 4｜跨部门 / 外协供应商免插件三维协同审阅

场景描述：通过 Phase 4 的单文件便携打包器，将精修白模与包络标尺内嵌为独立 `.html`，客户、采购与外协模具厂无需安装笨重专业 CAD，在手机或浏览器中即可 360° 旋转并拖动滑块剖析内部腔体结构。

本机实证： `04_viewer/proj_20261014_001_3D_Concept_Share.html`（68 MB，GLB + 概念图 + manifest 全内嵌，双击即看，零服务器、零依赖）。

四、项目核心创新点

创新点 1｜提出「几何真实优先（Geometry-First）」的跨模态尺寸锚定机制

解决了从 2D 概念图 → 3D Mesh → 参数化 CAD 全过程中「物理尺寸丢失」的核心难题。系统通过全局事务契约 `manifest.json` 贯穿始终：Phase 3 用 Blender 将归一化网格强制对齐至真实毫米包络（坐平 Z=0 基准面），Phase 5 首创「**白模三层高度（10% / 50% / 90%）激光切片采样法**」，把感性的美学长宽高比例精确翻译为理性 CAD 代码的草图尺寸约束。

实测：三层截面分别输出 `bottom_10pct / mid_50pct / top_90pct` 的 z、span_x、span_y 锚点并注入建模提示词，最终 CAD 包络与目标值偏差为 0。

创新点 2｜基于 OpenCascade 硬件级反馈的 Text-to-CAD「自愈闭环（Self-Healing Loop）」

打破大模型写 CAD 代码「一次生成成功率低、拓扑易崩溃」的瓶颈。系统把生成的代码置于沙箱运行，直接调用 OpenCascade 底层内核做数学级检验：实体 `isValid()` 拓扑合法性、体积 > 1 mm³、三轴 Bounding Box 误差严控在 **±1.5 mm** 内，并核查 STEP 实体文件确实落盘。一旦捕获 `BRep_API: command not done` 倒角报错或尺寸

超差，自动把报错堆栈回传主控模型进行最多 **5 轮**自我修复；失败代码与成功代码同时被捕获为 DPO 负 / 正样本。

实测：示范项目第 1 轮一次通过；基准题 `bench_01` 上旧主控同样一次通过（体积 70,262 mm³，包络 120×80×45）。

创新点 3｜「客观 DFM 物理信号 > VLM 主观打分 > 人类终审」的三级评判体系

不同于纯视觉系统仅靠多模态大模型「看图打分」，HyperDesign 坚持工程物理规律一票否决权。Phase 7 中系统向网格内部发射 **500 条反向法线射线（Ray-Casting）**量化测量真实局部壁厚分布（取 10% 分位最薄处 p10 作为判据），并结合面法向量倾角统计拔模斜度、检查水密性与包络漂移（>8% 淘汰）。只有通过物理 DFM 硬指标的方案，才进入 VLM 视觉评分与人工选品台，彻底杜绝「好看但造不出」的废案。

实测：Phase 3 生成式白模被该体系判为「不通过」（水密=否、p10=1.51 mm、拔模 0.84°），系统随即改以「白模只作造型锚点、制造实体由 Phase 5 按工艺铁律重建」的路径推进——评判体系真实发挥了拦截作用。

创新点 4｜零边际成本的「日常工作即训练（Work-as-Training）」DPO 进化飞轮

把模型微调数据收集完全隐形化融入设计师日常工作流：Phase 4 审阅台中，设计师从 4 张方案里勾选 1 张推进 3D 时，系统自动把 (Brief, 选中 Prompt, 淘汰 Prompt) 组装为视觉偏好样本对；Phase 5 自愈循环中，自动把 (建模需求, 编译通过且尺寸合规的代码, 报错或超差的代码) 捕获为 CAD 代码偏好样本对。配合 Unsloth 本地 4-bit QLoRA 与 DPO（直接偏好优化）及黄金基准集回归测试，无需额外标注人力、无需云端算力费用。

实测：一次审阅提交即自动落盘 3 条 `(prompt, chosen, rejected)`；Unsloth QLoRA+DPO 训练链路完整跑通（LoRA 40.37 M 可训练参数 / 占 0.52%，3 步 27.6 s），并成功导出 GGUF Q4_K_M 注册进 Ollama。

创新点 5｜单机消费级硬件下的「显存红绿灯」接力与国标制图直连

针对本地工作站同时部署 LLM、FLUX、TRELLIS 等多个重型模型极易爆显存（OOM）的痛点，设计了严格的显存生命周期管理：Ollama `keep_alive=0`、ComfyUI `POST /free`、TRELLIS `POST /unload` 三者在阶段边界联动卸载，使单张消费级 16GB 显卡能够平稳接力百亿参数级多模态流水线。同时在末端内置 GB/T 机械制图图层规范（实线切割层 / 虚线隐藏层 / 关联标注层 / 图框标题栏分层），真正走完从 AI 到工厂车间的「最后一公里」。

实测：曾定位并修复 Windows 提交内存（commit limit）耗尽导致的 `os error 1455`——ComfyUI 默认 pinned memory 占用 43.9 GB，叠加 33 GB UNet 与 33 GB 文本编码器后触顶；关闭 pinned memory 并迁移 32 GB 模型库后全链路稳定。

五、实测验证、已知限制与工程取舍

阶段	验收项	结论
Phase 1	私有规范数值原样引用	**PASS（2.4 / 1.44 / 1.8°）**
Phase 2	4 张概念图 + 纯灰背景 + 无裁切	**4/4 PASS**
Phase 3	清洗白模 GLB/STL + 真实包络回填	**PASS（388,391 面）**
Phase 3.5	DFM 硬规则 + VLM 双层初筛	白模 DFM 未通过（设计内预期，作造型锚点）
Phase 4	审阅台交互 + 提交归档 DPO	**PASS（3 条偏好样本对）**
Phase 5	BRep 合法 / 体积 / 包络 ±1.5 mm	**PASS（69042.2 mm³，120×80×45，Z=0）**
Phase 6	1:1 激光 DXF + A3 图 + 300dpi PDF	**PASS（4 图层 + 标题栏工艺铁律）**
Phase 7	DPO 训练 → GGUF → Ollama + 守门员回归	**机制 PASS；守门员判定「禁止切流」（样本不足）**

诚实声明（工程取舍与限制）：

1. **生成式白模的 DFM 不达标属行业固有现象**：单图重建的网格不水密、壁厚与拔模不可控。HyperDesign 的应对是把它降级为「造型比例参考」，制造实体由 Phase 5 依据企业工艺规范重新参数化生成，并通过 OCC 数学校验——这也正是三级评判体系存在的意义。
2. **DPO 效果需要样本量**：本次仅用 3 条偏好样本做机制验证，进化版（7B-Q4）在黄金基准上未超越旧主控（27B），守门员正确阻止了切流。按《工程文件》建议，攒够 50–100 条样本后再做正式进化。
3. **本机 CadQuery/OCP 原生扩展无法加载**（多个版本与解释器均复现），故 Phase 5/6 改用工程文件同样指定的 FreeCAD 自带 OpenCascade 内核；算法与交付物完全等价，CadQuery 版实现保留于仓库备查。
4. **未启用的规划项**：`blender-mcp` / `freecad-mcp` / CAD-COM 桥接在本机流程中未启用（全自动无头链路已覆盖需求），保留为人工精修接口。

六、参考文献

1. Xiang J., Lv B., Deng Y., et al. *Structured 3D Latents for Scalable and Versatile 3D Generation* (TRELLIS). arXiv:2412.01506, 2024. https://arxiv.org/abs/2412.01506
2. Chen J., Xiao S., Zhang P., Luo K., Lian D., Liu Z. *M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation* (BGE-M3). arXiv:2402.03216, 2024. https://arxiv.org/abs/2402.03216
3. Black Forest Labs. *FLUX.2: Frontier Visual Intelligence*. 2025. https://bfl.ai/blog/flux-2
4. Shen T., Munkberg J., Hasselgren J., et al. *Flexible Isosurface Extraction for Gradient-Based Mesh Optimization* (FlexiCubes). arXiv:2308.05371, SIGGRAPH 2023. https://arxiv.org/abs/2308.05371
5. Rafailov R., Sharma A., Mitchell E., et al. *Direct Preference Optimization: Your Language Model is Secretly a Reward Model*. arXiv:2305.18290, NeurIPS 2023. https://arxiv.org/abs/2305.18290

6. Dettmers T., Pagnoni A., Holtzman A., Zettlemoyer L. *QLoRA: Efficient Finetuning of Quantized LLMs*. arXiv:2305.14314, NeurIPS 2023. https://arxiv.org/abs/2305.14314
7. Liu X., Gong C., Liu Q. *Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow*. arXiv:2209.03003, ICLR 2023. https://arxiv.org/abs/2209.03003
8. Unsloth AI. *Unsloth: 2× faster LLM finetuning*（本地 4-bit QLoRA / DPO 训练框架）. https://github.com/unslothai/unsloth
9. Qdrant. *Qdrant Vector Database Documentation*（向量检索与 COSINE 距离度量）. https://qdrant.tech/documentation/
10. ezdxf. *ezdxf — Python DXF read/write library Documentation*（R2010 DXF 与图层 / 线型 / 标注 API）. https://ezdxf.readthedocs.io/
11. Open CASCADE Technology. *OCCT Documentation — HLR (Hidden Line Removal) & BRep Topology Validation*. https://dev.opencascade.org/doc/overview/html/
12. FreeCAD. *FreeCAD 1.1 Documentation — Part / TechDraw Workbench*. https://wiki.freecad.org/
13. Blender Foundation. *Blender 4.2 LTS Manual — Python API (bpy) 与网格处理*. https://docs.blender.org/manual/en/4.2/
14. three.js. *three.js Documentation — GLTFLoader / Clipping Planes / BoxHelper*. https://threejs.org/docs/
15. 中华人民共和国国家标准. *GB/T 14665 机械工程 CAD 制图规则*；*GB/T 1804 一般公差 未注公差的线性和角度尺寸的公差*.
16. 中华人民共和国国家标准. *GB/T 1182 产品几何技术规范(GPS) 几何公差*（图纸技术要求与检验依据引用）.
